

Wykorzystanie sieci neuronowych i algorytmu
najbliższych sąsiadów do implementacji
wirtualnego sensora temperatury zapłonu
kerozyny

Łukasz Meyer
Arkadiusz Piórkowski

14 stycznia 2018

Ścieżka prowadzenia projektu

1. Przegląd literatury
2. Wstępna ocena danych (wizualna, współczynnik R^2)
3. Opracowanie modelu opartego o sieć neuronową
4. Testy i optymalizacja sieci neuronowej
5. Opracowanie modelu opartego o algorytm k-NN
6. Testy i dobór parametrów modelu k-NN
7. Porównanie modeli, wyznaczenie średniej z dwóch modeli

Przegląd literatury

N. BOLF et al., Soft Sensors for Kerosene Properties Estimation and Control in ..., *Chem. Biochem. Eng. Q.* **23** (3) 277–286 (2009)

277

Soft Sensors for Kerosene Properties Estimation and Control in Crude Distillation Unit

N. Bolf, G. Galinec, and M. Ivandić

Faculty of Chemical Engineering and Technology,
University of Zagreb, Department of Measurements and Process Control,
Savska c. 16/5a, 10 000 Zagreb, Croatia

Original scientific paper

Received: March 17, 2008

Accepted: June 4, 2009

Neural network-based soft sensors are developed for kerosene properties estimation, a refinery crude distillation unit side product. Based on temperature and flow measurements, two soft sensors serve as the estimators for the kerosene distillation end point (95 %) and freezing point.

as estimators of distillation end point and kerosene freezing point:


- unstabilized naphtha temperature (*TC7*)
- kerosene temperature (*T1153*)
- kerosene flowrate (*F17152*)
- LGO temperature (*T1154*)
- LGO flowrate (*FC3*)
- crude oil inlet flowrate (*FC5_12*).

Kerosene properties were determined by carry-


Wstępna analiza danych

Parametr	R^2
FC0206	0.416
TI0208	0.411
TI0240	0.409
TI0265	0.363
FC0211	0.353
TI0206	0.339
TI0204	0.306
TI0250	0.295
TI0278	0.162

Tablica: Dopasowanie do prostej, uśrednianie wejść z 5 godzin przed pomiarem T_{A22}




Sieć neuronowa - idea przyrostów od poprzedniego pomiaru




- $T_{A22}(k-1)$ - poprzedni pomiar laboratoryjny. Uwzględnia jakość ropy i jej skład. (założenie: jakość i parametry ropy nie zmieniają się drastycznie z tygodnia na tydzień).
- Δu - przyrosty wejść (6 temperatur, 2 przepływy) względem chwili wykonania poprzedniego pomiaru laboratoryjnego

Uczenie sieci

Otrzymany zbiór danych uczących dzielony jest losowo na zbiory: uczący sieć i walidacyjny.




Rysunek: Wykorzystano sieć *feedforwardnet* i Neural Network Toolbox MATLABa




Rysunek: Przebieg błędu podczas uczenia sieci neuronowej

Rezultaty




Rysunek: Działanie modelu dla danych uczących; $E = 6.02\%$



Rysunek: Działanie modelu dla danych walidacyjnych(2); $E = 9.2\%$

Algorytm K-NN




Rysunek: Przepływ danych w algorytmie k-NN. Oznaczenia: X_t , Y_t - dane uczące; X_{in} - wejście dla którego ma być wyznaczone wyjście modelu; $d(X_t(i) - X_{in}) = ||X_t(i) - X_{in}||_2$.


Metody wyznaczania wag:

- Uśrednianie
- Wagi odwrotnie proporcjonalne do odległości
- Wagi próbkowane z rozkładu Gaussa w zależności od odległości

Dobór parametrów




Rysunek: Błąd względny dla danych walidacyjnych(1) w zależności od K . Według wykresu najlepszą metodą wyznaczania wartości wyjściowej jest uśrednienie wszystkich danych uczących...




Rysunek: Wagi pośrednie wyznaczone z wykorzystaniem rozkładu Gaussa. Wagi te są normalizowane, aby $\sum_i w_i = 1$

Rezultaty

$K = 5$, wagi wyznaczone z wykorzystaniem rozkładu Gaussa.




Rysunek: Działanie modelu KNN dla danych uczących; $E = 5.62\%$




Rysunek: Działanie modelu dla danych walidacyjnych(2); $E = 10.26\%$

Porównanie modeli, uśrednianie



Rysunek: Porównanie działania modeli dla danych walidacyjnych(2)



Rysunek: Model uśredniony dla danych walidacyjnych(2);
 $E = 3.84\%$